

Raport ZMUM

Miłosz Gronowski

`milosz.gronowski@student.pk.edu.pl`

18 maja 2026

1 Abstrakt

Celem projektu jest analiza danych klientów firmy telekomunikacyjnej oraz przygotowanie ich do zadania klasyfikacji polegającego na przewidywaniu odejścia klienta od usług firmy.

W ramach pracy zostaną przeprowadzone procesy wstępnego przetwarzania danych i metody imputacji danych. Ostatecznym celem projektu jest przygotowanie modelu klasyfikacji do przewidywania odejścia danego klienta od firmy oraz analiza wpływu zastosowanych metod na jakość naszej predykcji.

2 Wprowadzenie

Jednym z głównych wyzwań, przed którymi stoi wiele przedsiębiorstw, szczególnie w dynamicznych sektorach rynku, jest utrzymanie klienta. Wysoka konkurencja sprawia, że użytkownicy mogą łatwo zmieniać dostawcę usług, co prowadzi do strat finansowych dla firm.

Analiza zachowań klientów i identyfikacja czynników wpływających na ich decyzje, pozwala na skuteczniejsze zbieranie danych na temat obszarów, które powodują przepływy klientów oraz egzekucję przyjętej strategii firmy.

Dzięki temu przedsiębiorstwa mogą poprawiać jakość swoich usług oraz dostosowywać ofertę do potrzeb klientów.

3 Zbiór danych

W projekcie wykorzystano zbiór danych "Telco Customer Churn" [1], który zawiera informacje o klientach firmy telekomunikacyjnej. Zbiór ten obejmuje ponad 7000 rekordów oraz ponad 20 cech opisujących klientów.

Dane zawierają zarówno zmienne numeryczne (np. miesięczne opłaty, całkowite koszty, długość trwania umowy), jak i kategoryczne (np. płeć, rodzaj usług, typ umowy). Zmienną docelową jest zmienna binarna określająca, czy klient zrezygnował z usług (eng. Churn).

Szczegółowy opis i analiza kolumn znajdujących się w zbiorze danych:

- **CustomerID** - unikalny identyfikator klienta,
- **Gender** - płeć klienta,
- **SeniorCitizen** - informacja, czy klient jest seniorem,
- **Partner** - informacja, czy klient posiada partnera,
- **Dependents** - informacja, czy klient posiada osoby na utrzymaniu,
- **Tenure** - liczba miesięcy korzystania z usług,
- **PhoneService** - informacja, czy klient posiada usługę telefoniczną,
- **MultipleLines** - informacja, czy klient posiada wiele linii telefonicznych,
- **InternetService** - rodzaj usługi internetowej (DSL, Fiber optic, brak),
- **OnlineSecurity** - informacja o posiadaniu usługi bezpieczeństwa online (Tak, Nie, Brak usługi internetowej),
- **OnlineBackup** - informacja o usłudze tworzenia kopii zapasowych (Tak, Nie, Brak usługi internetowej),
- **DeviceProtection** - informacja o ochronie urządzeń (tak, nie, brak usługi internetowej),
- **TechSupport** - informacja o wsparciu technicznym (tak, nie, brak usługi internetowej),
- **StreamingTV** - informacja o usłudze streamingu telewizji (tak, nie, brak usługi internetowej),
- **StreamingMovies** - informacja o usłudze streamingu filmów (tak, nie, brak usługi internetowej),
- **Contract** - typ umowy (miesięczna, roczna, dwuletnia),
- **PaperlessBilling** - informacja o elektronicznym fakturowaniu,
- **PaymentMethod** - sposób płatności (Electronic check, Mailed check, Bank transfer (automatic), Credit card (automatic)),
- **MonthlyCharges** - miesięczna opłata za usługi,
- **TotalCharges** - całkowity koszt poniesiony przez klienta,
- **Churn** - zmienna docelowa określająca odejście klienta, na jej podstawie przeprowadzamy ostateczną klasyfikację.

Zbiór danych zawiera zarówno dane demograficzne, jak i informacje dotyczące korzystania z usług, co pozwala na kompleksową analizę czynników wpływających na decyzję klienta o odejściu.

Ostateczny rezultat projektu pozwala zobrazować, które czynniki są kluczowe w kontekście utrzymania klienta przy ofercie, a także które często prowadzą do tego, że klient rozstaje się z usługami przedsiębiorstwa.

4 Przegląd literatury

Analiza odpływu klientów jest jednym z najczęściej badanych zagadnień w sektorze telekomunikacyjnym, gdzie pozyskanie nowych klientów często jest wiele droższe od utrzymania obecnego. Przeglądając literaturę związaną z zagadnieniem klasyfikacji, dużą wagę przykładają do jakości wejściowych danych i ich wpływu na precyzję modelu. Prace takie jak te autorstwa Little'a i Rubina [3], pokazują wyższą skuteczność zaawansowanych metod imputacji w dopasowywaniu danych. Projekty, takie jak "Telco Customer Churn" z repozytorium Geo-y20 [2] pokazują częste użycie klasyfikatorów Random Forest oraz XGBoost ze względu na odporność na wartości odstające. W przytoczonym projekcie poza samą klasyfikacją, autor skupił się także na aspekcie biznesowym i dostarczeniu rekomendacji, a także rozszerzyli proces o zaawansowane eksploracje danych (EDA) [4], by zrozumieć profil klienta skłonnego do rezygnacji z usług.

5 Motywacja

Jako analityk sprzedaży z zawodu lubię podchodzić w sposób analityczny do pewnych danych związanych bezpośrednio ze sprzedażą, świadczeniem usług, decyzjami konsumentów, czy klientów oraz śledzeniem tego, co stoi za wyborem przez nich, tego czy innego produktu.

Wiem także, jak dużym wyzwaniem dla biznesu jest zrozumienie mechanizmów, które stoją za lojalnością i decyzjami klienta oraz jak duża jest potrzeba na zbieranie wartościowych i merytorycznych danych dla procesu preewaluacji, ewaluacji oraz postewaluacji. Konstruktywne wnioski budowane na podstawie zgromadzonych i uporządkowanych danych, mogą znacząco ulepszyć sposób kierowania oferty dla konsumenta i poprawić jakość świadczonych usług.

Skuteczna analiza pozwala podnosić świadomość skutków, które mogą mieć pewne decyzje biznesowe i sposoby świadczenia usług. Projekty jak te, pozwalają na próbę wyciągnięcia rekomendacji dla danego przedsiębiorstwa i zbadania korelacji pewnych czynników w odniesieniu do zarządzania firmą.

W odniesieniu tych stwierdzeń do wybranego zbioru danych - zgromadzony materiał posiada wiele różnorodnych cech, na którym mogę przetestować proces analizy danych dla konkretnego przedsiębiorstwa, przeanalizować wyniki i zależności pomiędzy danymi, a ostateczną decyzją o odejściu od usług firmy. Pozwala także spróbować wyciągnąć ostateczne wnioski i rekomendacje na ich podstawie.

6 Ewaluacja

Głównym celem ewaluacji jest weryfikacja metod wstępnego przetwarzania danych i ich wpływ na jakość końcowej skuteczności predykcji modelu klasyfikacyjnego w kontekście przewidywania, czy klient odejdzie od usług, czy nie na podstawie zgromadzonych danych.

Predykcje na temat projektu i oczekiwany wynik:

- **Oczekiwany wynik porównania metod imputacji** - zaawansowane metody imputacji danych takie jak np. algorytm KNN czy techniki AutoML, powinny zachować większą spójność danych niż proste metody statystyczne np. średnia, mediana, moda. Satysfakcjonującym wynikiem będzie wykazanie różnic w skuteczności modelu pomiędzy ośmioma wariantami zbioru danych, które będą wygenerowane w procesie preprocesingu,
- **Wskaźnik czułości odejścia klienta** - z punktu czysto biznesowego, ważny będzie wysoki wskaźnik *Recall* (czułość) dla klasy pozytywnej (odejście klienta). Koszt przeoczenia klienta zamierzającego odejść (False Negative) jest znacznie wyższy niż koszt błędnego zaklasyfikowania zostającego klienta do grupy ryzyka (False Positive),
- **Potencjał wdrożeniowy** - Wynik na poziomie F1-score powyżej 75-80% powinien być satysfakcjonujący, aby brać pod uwagę predykcje modelu. Taki model mógłby stanowić pewnego rodzaju "czerwoną lampkę", która może służyć do wczesnego ostrzegania, generując listy rankingowe klientów do działu zajmującego się utrzymaniem klienta przy usługach firmy, co pozwoliłoby na podejmowanie proaktywnych działań naprawczych,
- **Analiza zależności** - Sukcesem będzie nie tylko wysoka trafność predykcji, ale także czytelność modelu – czyli możliwość wskazania, które cechy mają największy wpływ na decyzję o odejściu, co umożliwi sformułowanie konkretnych rekomendacji i wniosków. Znaczący wpływ danej cechy na odejście klienta od firmy, może świadczyć o konieczności poprawy oferty z uwzględnieniem danej cechy,

Projekt ma także na celu próbę sformułowania wniosków i rekomendacji w zakresie ulepszania jakości świadczonych usług, poprzez analizę głównych cech, które ostatecznie mają wpływ na decyzje klienta o zakończeniu pobierania usług.

7 Zasoby

Wykorzystywane zasoby:

- **Visual Studio Code** - główne środowisko programistyczne, wykorzystywane do edycji kodu i zarządzania projektem,
- **Python 3.12** - język programowania stanowiący fundament implementacji wszystkich algorytmów,
- **Notebook Jupyter** - struktura dokumentująca proces projektu, pozwalająca na jednoczesne uruchamianie kodu, prezentację wyników oraz zamieszczanie opisów analitycznych,

Biblioteki i pakiety:

- **Pandas** - główne narzędzie do wczytywania zbioru danych, czyszczenia i transformacji tabelami,
- **Numpy** - biblioteka wykorzystywana do obliczeń numerycznych,
- **Matplotlib i Seaborn** - biblioteki służące do generowania niezbędnych wizualizacji, takich jak: histogramy, wykresy pudełkowe (box-plot) oraz mapy korelacji,
- **Sklearn** - wykorzystana do implementacji zaawansowanych algorytmów uzupełniania braków danych oraz do tworzenia modeli,
- **flaml** - biblioteka wykorzystywana do testu AutoML,

Metody imputacji danych:

W celu uzupełnienia brakujących wartości (10% dla każdej cechy) oraz zbadania wpływu sposobu uzupełniania danych na spójność logiczną zbioru, zastosowano cztery zróżnicowane strategie, które opisano w dziale Zastosowane metody - Imputacja braków danych 8.3.

8 Zastosowane metody

W projekcie wykorzystano zestaw metod służących do kompleksowej obróbki danych, radzenia sobie z brakami, standaryzacją oraz analizą danych klientów firmy telekomunikacyjnej. Każda z metod została dobrana tak, aby umożliwić porównanie różnych podejść i ocenę ich wpływu na końcowy zbiór danych.

8.1 Czyszczenie danych

- Usunięcie kolumny **CustomerID** z powodu występowania wyłącznie unikalnych danych, co przekłada się na brak wartości informacyjnej i ryzyko przeuczenia,

8.2 Tworzenie braków w danych

- Ze względu na pełną kompletność i zgodność typów danych w każdej kolumnie naszego zbioru danych, stworzono losową metodą sztuczne braki - 1/10 danych dla każdej kolumny z wyłączeniem kolumny **Churn**, która odpowiada za końcową klasyfikację,
- Wartości w kolumnach **OnlineSecurity**, **OnlineBackup**, **DeviceProtection**, **TechSupport**, **StreamingTV**, **StreamingMovies** są zależne od wartości kolumny **InternetService** - jeżeli jej wartość wskazuje na brak usługi internetowej, wszystkie te kolumny mają wartości *No internet Service* - w naszym przypadku jednak tworzymy sztuczne braki również w tych kolumnach, prowadzi to do abstrakcyjnych rekordów w utworzonych zbiorach danych, ale pomoże lepiej zobrazować różnice w użytych metodach imputacji danych,

- Na potrzeby imputacji danych zmieniamy typ danych dla kolumn, które muszą być numeryczne do obliczeń statystycznych - kolumna **TotalCharges**,
- Zmieniamy typ kolumny z Float64 na Int64 - kolumna **SeniorCitizen**,

8.3 Imputacja braków danych

Zastosowano kilka metod imputacji, aby umożliwić porównanie ich wpływu na dane:

- **Prosta metoda statystyczna** – bazowe podejście polegające na uzupełnianiu braków wartością mediany dla danych numerycznych (odporność na wartości odstające) oraz mody dla danych kategoriycznych (najczęstsza wartość),
- **Prosta metoda losowości** – metoda wstawiania losowo wybranych wartości spośród już istniejących w danej kolumnie, co pozwala na zachowanie naturalnego rozkładu cechy bez sztucznej koncentracji wokół średniej,
- **KNN (K-Nearest Neighbors)** – zaawansowane modelowe uzupełnianie danych, gdzie brakująca wartość jest estymowana na podstawie k ($k = 5$) najbardziej podobnych rekordów (sąsiadów) w wielowymiarowej przestrzeni cech,
- **Iterative Imputer (MICE / AutoML-style)** – zaawansowana metoda klasy modelowej, wykorzystująca regresję do przewidywania braków, traktuje ona każdą cechę jako funkcję pozostałych zmiennych, co pozwala na zachowanie głębokich korelacji logicznych w zbiorze danych,

9 Eksperyment


9.1 Preprocessing

9.1.1 Wprowadzenie do preprocessingu

Wczytano zbiór danych, usunięto kolumny unikalne, sprawdzono braki w danych i utworzono je sztucznie dla procesu imputacji danych. Przetestowano cztery metody imputacji.

9.1.2 Rozkład klasyfikacji

Cecha *Churn* na, której bazujemy naszą klasyfikację ma lekką dysproporcję (ok. 3:1 na rzecz klientów, którzy nie odeszli). Na podstawie tego wykresu możemy stwierdzić, że podczas procesu trenowania modeli klasyfikacyjnych, należy zwrócić szczególną uwagę na metryki, które pozwolą skuteczniej wykryć mniejszościową klasę klientów odchodzących.



Rysunek 1: Rozkład klasyfikacji - cecha *Churn*

9.1.3 Eksperyment porównawczy metod imputacji dla kolumn zależnych od siebie

Wprowadzono braki danych w cechach kategoriycznych, które są zależne od usługi internetowej. Pozwoliło to na sprawdzenie, jak poszczególne metody imputacji (KNN, AutoML) radzą sobie z logicznymi zależnościami między kolumnami. Całość porównano także z oryginalnym zbiorem danych.

Oryginalny zbiór danych nie posiadał żadnych błędów logicznych, co pozwoliło zbadać jak różne metody imputacji poradzą sobie z tym problemem. Zbadano poszczególne metody za pomocą dwóch wskaźników:

- Ilości niepoprawnych wartości (wartości YES/NO w kolumnach zależnych przy braku serwisu internetowego oraz wartości NO INTERNET SERVICE w kolumnach zależnych przy posiadaniu serwisu internetowego)
- Ilości niepoprawnych rekordów (co najmniej jedna niepoprawna wartość w rekordzie).

Omówienie wyników analizy jakości imputacji:

- **Prosta metoda statystyczna** – wygenerowała błędy w 11,66% rekordów, wynika to z faktu, że metoda przypisuje najczęściej występującą wartość bez analizy korelacji poszczególnych cech, w efekcie klientom bez in-

ternetu przypisano wartości sugerujące korzystanie z usług dodatkowych, wynik ten mógłby być znacznie wyższy przy innym rozkładzie cech, szczególnie widać tu duże różnice pomiędzy kategoriami przez użycie najczęściej występującej wartości

Błędne przypisania:

- YES: 0
- NO: 857
- NO INTERNET SERVICE: 877

Niepoprawne logicznie:

- WARTOŚCI: 3,44%
- REKORDY: 11,66%

- **Prosta metoda losowości** – wygenerowała błędy w 20,73% rekordów, wprowadziła błędy w każdej kategorii, co czyni zbiór danych niewiarygodnym do dalszych analiz predykcyjnych

Błędne przypisania:

- YES: 590
- NO: 809
- NO INTERNET SERVICE: 1383

Niepoprawne logicznie:

- WARTOŚCI: 5,41%
- REKORDY: 20,73%

- **KNN (K-Nearest Neighbors)** – metoda po zastosowaniu kodowania porządkowego (Ordinal Encoding) wykazała się różną skutecznością, pomimo tego, że znacznie lepiej od prostych metod potrafi identyfikować braki usług, wykazuje jednak błędy na poziomie 12,79% rekordów za sprawą kopiowania zachowań "sąsiadów" - algorytm błędnie dobiera wartości na podstawie podobieństwa demograficznego, czy finansowego, algorytm ma tendencję kopiowania statusu usług w kolumnach zależnych, pomimo tego że status posiadania usługi internetowej może się różnić w tych rekordach

Błędne przypisania:

- YES: 24
- NO: 28
- NO INTERNET SERVICE: 992

Niepoprawne logicznie:

- WARTOŚCI: 2,05%

– REKORDY: 12,79%


- **Iterative Imputer (MICE / AutoML-style)** – metoda iteracyjna uzyskała najwyższy wskaźnik rekordów z błędem logicznym - 23,80% rekordów, wynikający głównie z błędnej klasyfikacji usług u klientów posiadających internet, model regresyjny MICE, szukając globalnych korelacji, nadmiernie generalizuje cechy wspólne dla osób o niskich przychodach lub specyficznych pakietach usług, przypisując im status braku internetu niezgodnie z prawdą

Błędne przypisania:


- YES: 0
- NO: 590
- NO INTERNET SERVICE: 2121

Niepoprawne logicznie:

- WARTOŚCI: 5,37%
- REKORDY: 23,80%



Rysunek 2: Porównanie procentowe ilości niepoprawnych logicznie wartości



Rysunek 3: Porównanie procentowe ilości niepoprawnych logicznie rekordów

Po skończonym eksperymencie związanym z badaniem, jak metody poradzą sobie z kolumnami zależnymi dodano przy imputacji poprawki na uzupełnianie dane, tak by w finalnych zbiorach nie było już błędów logicznych:

- Dla błędów YES/NO - czyli przypisaniu tych wartości do rekordów bez usługi internetowej - zamieniamy je w procesie poprawiania na wartość No INTERNET SERVICE
- Dla błędów No INTERNET SERVICE - czyli przypisaniu tej wartości do rekordów z usługą internetową - zamieniamy je na wartości YES/NO losując je zgodnie z rozkładem proporcji istniejących rekordów - robimy to dla każdej metody


9.1.4 Macierze korelacji

Analiza macierzy korelacji stanowiła ważny etap weryfikacji jakości imputacji, pozwalała porównać korelacje cech dla oryginalnego zbioru danych i poszczególnych metod imputacji.


Wizualna analiza porównawcza pokazała różnice w nasyceniu barw, co przekłada się na powiązania cech:

- **Metoda statystyczna** - zaobserwowano zjawisko mniejszego nasycenia barw w kluczowych blokach numerycznych, takich jak relacja *MonthlyCharges* i *TotalCharges*, wynika to z faktu, że imputacja wartością stałą np. medianą, modą sztucznie ogranicza wariancję, prowadząc do niedoszacowania powiązań cech.

- **Metoda losowa** - wyższy poziom szumu informacyjnego, powstanie przypadkowych powiązań w obszarach o niskiej korelacji
- **Metody KNN i MICE** - wykazały najwyższą zbieżność wizualną z oryginałem, szczególnie widać spójność cech dla relacji *MonthlyCharges* i *TotalCharges*, która jest bardziej nasycona jak w oryginale




Rysunek 4: Macierz korelacji - oryginalny zbiór



Rysunek 5: Relacja MonthlyCharges i TotalCharges dla oryginalnego zbioru



Rysunek 6: Relacja MonthlyCharges i TotalCharges dla prostej metody statystycznej



Rysunek 7: Relacja MonthlyCharges i TotalCharges dla metody MICE


Podsumowanie i wybór optymalnych metod

Na podstawie analizy macierzy korelacji, za najbardziej efektywne metody uznano zaawansowane metody imputacji - KNN, MICE. Najpełniej oddają charakterystykę oryginalnego zbioru, eliminując typowe błędy dla metod prostych. Największą przewagą zaawansowanych metod jest zachowanie hierarchii ważności zmiennych. Bardzo ważne okazało się także upewnienie się, że w zbiorach nie występują błędy logiczne.

9.1.5 Wykresy rozkładu


Celem analizy wykresów rozkładu jest weryfikacja, w jakim stopniu wybrane techniki imputacji zachowały naturalną charakterystykę statystyczną zbioru danych. Porównanie rozkładów gęstości (KDE) pozwala na identyfikację anomalii, takich jak np. przesunięcie spodziewanych wartości. Analizie poddano numeryczne cechy: *tenure*, *MonthlyCharges* oraz *TotalCharges*.

Tenure (Staż klienta)



Rysunek 8: Rozkład stażu klienta (*tenure*) dla zbioru oryginalnego.

W zbiorze oryginalnym cecha posiada rozkład bimodalny. Widać dwie dominujące grupy - nowi klienci (staż poniżej 5 miesięcy) oraz lojalni klienci (staż powyżej 65 miesięcy).




Rysunek 9: Zestawienie linii gęstości KDE dla cechy *tenure* — porównanie metod.

Wnioski i analiza porównawcza: Nałożenie linii gęstości pozwala pokazać wady i zalety poszczególnych metod:


- **Metoda statystyczna** - drastyczne zniekształcenie rozkładu, przez wysoki wzrost wartości około 30 miesięcy, spowodowane użyciem mediany do uzupełnienia braków w danych
- **Metody losowa, KNN i MICE** - najwyższa zbieżność z oryginałem, zachowując wygląd rozkładu
- **Anomalia metody MICE** - linia MICE jako jedyna wykracza poza zakres od 0 do 80 przez matematyczny charakter metody, która bez przycięcia może generować wartości fizycznie niemożliwe

MonthlyCharges (Opłaty miesięczne)



Rysunek 10: Rozkład opłat miesięcznych (*MonthlyCharges*) dla zbioru oryginalnego.

W zbiorze oryginalnym cecha posiada rozkład wielomodalny. Największe grupy klientów są w okolicach wartości 20 - podstawowe usługi, większe wznieśnienie jest także w okolicach wartości 50-110 - rozszerzone usługi.




Rysunek 11: Zestawienie linii gęstości KDE dla cechy *MonthlyCharges* — porównanie metod.

Wnioski i analiza porównawcza: Nałożenie linii gęstości pozwala pokazać wady i zalety poszczególnych metod:


- **Metoda statystyczna** - największa zmiana rozkładu przez użycie mediany w okolicy wartości 70, nienaturalny, wysoki szczyt
- **Metody losowa** - najwyższa zbieżność z oryginałem, zachowując wygląd rozkładu, dobre wyniki metody dla wykresów rozkładu
- **Metoda KNN** - wysoka zgodność, szczególnie w pierwszym ekstremum lokalnym w szczycie niskich opłat
- **Metoda MICE** - minimalny rozjazd względem oryginalnego zbioru, tendencja do lekkiego wygładzania przejść między lokalnymi ekstremami

TotalCharges (Łączne opłaty)



Rysunek 12: Rozkład łącznych opłat (*TotalCharges*) dla zbioru oryginalnego.

W zbiorze oryginalnym cecha posiada wyraźny rozkład prawoskośny. Największa liczebność występuje dla niskich wartości (nowi klienci), natomiast wraz ze wzrostem kwoty liczebność systematycznie spada, tworząc tzw. długi ogon rozkładu.



Rysunek 13: Zestawienie linii gęstości KDE dla cechy *TotalCharges* — porównanie metod.

Wnioski i analiza porównawcza: Nałożenie linii gęstości pozwala pokazać wady i zalety poszczególnych metod:


- **Metoda statystyczna** - największa zmiana rozkładu, mediana wprowadziła sztuczne wybrzuszenie w okolicy wartości 1500, niszcząc płynność przejścia rozkładu prawoskośnego
- **Metoda losowa i KNN** - wykazują niemal idealne pokrycie z linią oryginału
- **Metoda MICE** - bardzo dobra zgodność, choć podobnie jak w przypadku *tenure*, widoczna jest anomalia w postaci generowania wartości poniżej zera

Podsumowanie analizy rozkładów Zbiorcza analiza trzech kluczowych cech numerycznych pozwala na sformułowanie jednoznacznych rekomendacji:


- Dyskwalifikacja metody statystycznej: Użycie mediany w każdym przypadku doprowadziło do powstania nienaturalnych szczytów, które drastycznie zaniżają zgodność zbioru
- Pozostałe metody poprawnie zachowują wykres rozkładu, szczególnie metoda losowa i metoda KNN
- Metoda MICE powinna mieć ograniczenie przed wartościami nierealnymi, gdyż generowała wartości fizycznie niemożliwe ze względu na swój charakter

9.1.6 Wykresy pudełkowe

Sporządzono box-ploty dla każdego z czterech datasetów oraz oryginału. Różnice pomiędzy metodami losową, KNN i MICE są znikome, poprawnie odtworzyły rozstrzał danych oryginalnych. Różnica natomiast występuje w metodzie statystycznej, gdzie wykres pudełkowy może wydawać się nieco węższy, a wąsy krótsze, ponieważ sztuczne wstawienie tej samej wartości (mediany) w wiele miejsc ściąga rozkład do środka, sztucznie zaniżając zmienność. Nie odnotowano punktów poza wąsami wykresów.



Rysunek 14: Wykresy pudełkowe dla metody prostej statystycznej.




Rysunek 15: Wykresy pudełkowe dla metody MICE

9.1.7 Wykresy relacji (pair-plots)


Sporządzono pair-ploty dla każdego z czterech datasetów. Różnice pomiędzy metodami losową, KNN i MICE są znikome i pokazują naturalne rozkłady, podczas gdy metoda statystyczna pokazuje znaczące błędy na wartościach mediany. Dla metody statystycznej pojawiają się nienaturalne "linie" punktów, dla porównania metoda MICE ma punkty płynnie rozproszone.

Zaobserwowano silną, prawie liniową zależność pomiędzy stażem, a opłatami całkowitymi co jest logicznie uzasadnione. Mimo silnego wymieszania się

grup klientów odchodzących i pozostających, można zauważyć pewne tendencje i trendy skupiania się klas. Klasa klientów odchodzących (kolor zielony) dominuje u osób z krótszym stażem oraz relatywnie wyższych opłatach miesięcznych. Klasa klientów pozostających (kolor niebieski) przeważa u osób z dłuższym stażem oraz niższych opłatach. Same te wykresy mogą sugerować już pewne hipotezy, na temat tego gdzie może być pole do poprawy, aby utrzymać większą część klientów. Mimo widocznych trendów, brakuje wyraźnie odseparowanych skupisk, co sugeruje, że separacja klas będzie wymagała nieliniowych modeli uczenia maszynowego, by wyciągnąć większą liczbę zależności i poprawnie klasyfikować przypadki graniczne.



Rysunek 16: Wykres pair-plot dla metody prostej statystycznej.



Rysunek 17: Wykresy pair-plot dla metody MICE

9.1.8 Standaryzacja

Przeskalowano zmienne w celu ujednolicenia zakresów wartości wszystkich cech, by zapobiec dominacji zmiennych o dużych wartościach. Zastosowano dwa warianty standaryzacji:

- **Wariant A (Normalizacja Min-Max)** - przekształcenie danych do sztywnego przedziału $[0, 1]$, metoda zachowuje oryginalną strukturę rozkładu, ale jest wrażliwa na wartości odstające
- **Wariant B (Standaryzacja Z-Score)** - centruje dane wokół średniej równej 0 z odchyleniem standardowym wynoszącym 1, podejście rekomendowane dla większości algorytmów klasyfikacyjnych, takich jak regresja logistyczna czy maszyny wektorów nośnych (SVM).

Dla każdego datasetu uzyskanego czterema metodami imputacji, stworzono po dwa warianty - A i B.

9.2 Trening modelu

9.2.1 Podsumowanie datasetów po procesie pre-processingu

Lista datasetów po procesie pre-processingu (metoda imputacji i standaryzacji):

- **1A** - Statystyczna, MinMax
- **1B** - Statystyczna, Std
- **2A** - Losowa, MinMax
- **2B** - Losowa, Std
- **3A** - KNN, MinMax
- **3B** - KNN, Std
- **4A** - MICE, MinMax
- **4B** - MICE, Std

9.2.2 Wybór modeli

Lista wybranych do naszego projektu modeli klasyfikacji z biblioteki scikit learn:

- **Logistic Regression** - model wyznaczający prawdopodobieństwo przynależności do klasy za pomocą funkcji sigmoidalnej
- **Random Forest** - klasyfikator powstały z połączenia wielu drzew decyzyjnych poprzez proces agregacji
- **SVM** - algorytm dążący do maksymalizacji marginesu między klasami

- **KNN Classifier** - model "uczenia leniwego", który klasyfikuje nową próbkę na podstawie najbliższych sąsiadów dla danej cechy

Wybór 4 modeli sprawił, że po zakończonym treningu otrzymano 32 modele (4 modele * 4 metody imputacji * 2 metody standaryzacji).

9.2.3 Podział danych na zbiory

Każdy z ośmiu wariantów zbioru danych podzielono na zbiór treningowy (70%) oraz zbiór testowy (30%) z wykorzystaniem stratyfikacji, co zapewniło nam równe proporcje klasyfikacji w obu grupach. Zrezygnowano z wydzielania stałego zbioru walidacyjnego na rzecz k-krotnej walidacji krzyżowej przeprowadzanej wewnątrz bazy uczącej. Pozwala to na efektywniejsze wykorzystanie danych, szczególnie ważne przy zbiorach średniej wielkości. Zbiór testowy został odizolowany całkowicie i służył jedynie do finalnej, obiektywnej oceny kombinacji modelu, metody imputacji i metody standaryzacji.

9.2.4 Implementacja procesu uczenia i walidacji

Przeprowadzono pełen proces uczenia się i walidacji wybranych klasyfikatorów na ośmiu wariantach przygotowania danych. Wykorzystano metodę 10-krotnej walidacji krzyżowej, która polega na wielokrotnym podziale zbioru treningowego na mniejsze podzbiory w celu uśrednienia wyników i wyeliminowania wpływu przypadku. Dla każdego modelu obliczono miary dokładności (ACC) oraz wynik F1, co pozwoliło na obiektywną ocenę skuteczności przewidywania odejść klientów (*Churn*). Zastosowano pętlę, która automatycznie testuje 32 unikalne kombinacje, co umożliwia identyfikację najskuteczniejszego podejścia. Końcowym wynikiem jest ranking na podstawie wartości ACC oraz wartości F1. Wynik jest średnią uzyskaną z 10 pomiarów, co skutecznie eliminuje wpływ losowego podziału danych na ocenę jakości algorytmu. Dzięki temu wyniki ACC i F1 nie opisują jedynie skuteczności na konkretnym wycinku danych, ale reprezentują realną zdolność uogólniania modeli na nieznane wcześniej przykłady.

9.2.5 Wyniki eksperymentów i analiza porównawcza

Zestawiono wyniki dla 32 unikalnych kombinacji modeli klasyfikacyjnych oraz metod wstępnego przetwarzania danych. Skuteczność algorytmów oceniona na podstawie średniej dokładności (ACC) oraz miary F1, uzyskanych w drodze 10-krotnej walidacji krzyżowej.

RANKING WYNIKÓW TRENINGU MODELI				
Dataset	Model	CV_Accuracy	CV_F1_Score	
MICE_Std	Logistic Regression	0.801014	0.589149	
KNN_Std	Logistic Regression	0.800203	0.587840	
MICE_MinMax	Logistic Regression	0.801014	0.587169	
KNN_MinMax	Logistic Regression	0.799189	0.586746	
Statystyczna_MinMax	Logistic Regression	0.798986	0.584748	
Statystyczna_Std	Logistic Regression	0.797566	0.580450	
MICE_Std	SVM	0.798377	0.562974	
KNN_Std	SVM	0.796552	0.556099	
KNN_MinMax	SVM	0.795538	0.554690	
MICE_Std	Random Forest	0.790872	0.547847	
MICE_MinMax	SVM	0.793103	0.547585	
Statystyczna_Std	SVM	0.792495	0.546227	
Losowa_MinMax	Logistic Regression	0.788641	0.545875	
KNN_MinMax	Random Forest	0.789249	0.545675	
MICE_MinMax	Random Forest	0.790264	0.545529	
Losowa_Std	Logistic Regression	0.788032	0.545183	
KNN_Std	Random Forest	0.787424	0.542789	
Statystyczna_MinMax	SVM	0.788438	0.541712	
Statystyczna_MinMax	Random Forest	0.783570	0.537231	
Statystyczna_Std	Random Forest	0.782961	0.535378	
MICE_Std	KNN Classifier	0.753550	0.523672	
MICE_MinMax	KNN Classifier	0.753955	0.522610	
Losowa_MinMax	Random Forest	0.782353	0.522041	
KNN_MinMax	KNN Classifier	0.753955	0.521902	
Losowa_Std	Random Forest	0.782150	0.521888	
Losowa_Std	SVM	0.787627	0.521442	
KNN_Std	KNN Classifier	0.752941	0.520867	
Statystyczna_Std	KNN Classifier	0.745842	0.511551	
Losowa_MinMax	SVM	0.785801	0.510198	
Statystyczna_MinMax	KNN Classifier	0.745436	0.505278	
Losowa_Std	KNN Classifier	0.745436	0.488034	
Losowa_MinMax	KNN Classifier	0.740568	0.481718	

Rysunek 18: Ranking 32 kombinacji (model x metoda imputacji x metoda standaryzacji).

Analiza wyników pozwoliła dojść do następujących wniosków:

- **Przewaga Regresji Logistycznej** - Najwyższą skuteczność predykcji-
ną odnotowano dla modelu Regresji Logistycznej, której różne warianty
uplasowały się na pierwszych sześciu miejscach w rankingu, osiągając wy-
nik F1 na poziomie około 58-59%. Sugeruje to, że charakter powiązań
między cechami w badanym zbiorze danych jest zbliżony do liniowego, co
prosta funkcja sigmoidalna potrafi efektywnie wykorzystać.
- **Wpływ metody imputacji** - Najlepsze rezultaty uzyskano przy za-
stosowaniu zaawansowanych metod uzupełniania braków danych - MICE

oraz KNN Imputer. Najslabiej wypada imputacja losowa, co szczególnie widać na przykładzie Regresji Logistycznej, której warianty z losową imputacją danych odstają od reszty wariantów. Potwierdza to zasadność stosowania algorytmów uwzględniających korelacje między cechami podczas rekonstrukcji brakujących wartości.

- **Metody standaryzacji** - Wyniki pokazują lekką przewagę standaryzacji Std nad skalowaniem Min-Max, szczególnie dla modeli wrażliwych na rozkład cech, takich jak SVM czy Regresja Logistyczna.
- **Wyniki ACC i F1** - Pomimo dobrej dokładności (ACC) oscylującej na poziomie około 74-81%, wynik F1 utrzymuje się na niższym poziomie około 48-59%. Wynikać to z niebalansowania klas w zbiorze - modele poprawnie klasyfikują większość klientów lojalnych, jednak wciąż napotykają wyzwania przy wyłapywaniu osób odchodzących (*Churn*).


Jako optymalną kombinację do dalszych prac wyłoniono model Regresji Logistycznej trenowany na zbiorze danych z imputacją MICE i poddany standaryzacji Std, który w końcowym rankingu zajął 1 miejsce z wynikami: ACC 80,1014% oraz F1 58,9149%.

9.2.6 Macierz pomyłek dla zwycięskiej kombinacji

Dla najlepszej z 32 kombinacji (Regresja Logistyczna, metoda amputacji MICE i metoda Standaryzacji Std) wykonano macierz pomyłek, by sprawdzić jaki jest rozkład źle przewidzianych rekordów.

Wnioski na podstawie macierzy pomyłek zwycięskiej kombinacji:

- **Wysoka skuteczność w klasie negatywnej** - Wyniki wskazują na trafne identyfikowanie klientów lojalnych. Błąd typu FP, czyli błędne uznanie lojalnego klienta za odchodzącego jest stosunkowo niski. Z biznesowego punktu widzenia, oznacza to małe ryzyko ponoszenia dodatkowych kosztów w postaci akcji retencyjnych dla osób, które i tak by nie odeszły.
- **Niska skuteczność w klasie pozytywnej** - Wyzwanie widać za to w wynikach w klasie pozytywnej. Niska skuteczność w tej klasie jest przyczyną niskiego wyniku F1. Model wyłapał jedynie 704 przypadki odejść pomijając niemal tyle samo, czyli 604 przypadki.
- **Czułość** - Model wyłapuje około 54% wszystkich faktycznych odejść, co pokazuje, że przewidywanie rezygnacji klienta na podstawie dostępnych cech jest zadaniem trudnym, a ich zachowania są mocno zbliżone do osób, które planują pozostać.
- **Precyzja** - Gdy model wskazuje, że ktoś odejdzie, ma rację w około 65% przypadków.



Rysunek 19: Macierz pomyłek dla zwycięskiej kombinacji.

Podsumowanie:

Macierz dokładnie pokazuje przyczyny niskiego wyniku F1 na poziomie 59%, nawet dla najlepszej kombinacji. Model jest zachowawczy - woli nie ryzykować błędnej diagnozy, przez co przegapia niemal połowę klientów odchodzących, ale za to rzadziej myli się, gdy już wskaże zagrożenie. Jest to efekt niezbalansowanych klas w zbiorze danych. W optymalizacji należy sprawdzić, czy zmiana progu klasyfikacji lub waga klas pozwoli na uzyskanie lepszych wyników, co może podnieść wynik F1.

9.3 Optymalizacja

9.3.1 Proces optymalizacji

W ramach etapu optymalizacji podjęto próbę poprawy skuteczności wyłonionego wcześniej modelu Regresji Logistycznej (wariant z MICE i standaryzacją) poprzez dostrojenie jego hiperparametrów. Wykorzystano technikę przeszukiwania siatki (*Grid Search*) z zastosowaniem 10-krotnej walidacji krzyżowej, koncentrując się na optymalizacji wyniku F1. To pozwoliło na wyciągnięcie takiego zestawu parametrów, który uzyskał najlepszy wynik F1 na danym zbiorze. Ba-

daniu poddano wpływ takich parametrów jak:

- **Parametr C** - Wpływ siły regularyzacji. Im większa wartość tym model ma większą swobodę.
- **Penalty** - Rodzaj kary, normy L1 i L2.
- **Class_weight (Wagi klas)** - Zastosowano zbalansowane wagi klas, co jest szczególnie ważne przy nierównym rozkładzie cechy klasyfikującej jak w naszym przypadku.
- **Tol (tolerancja)** - precyzja zatrzymania obliczeń.
- **Fit Intercept** - czy prosta regresji może przesuwac się po osi Y.

9.3.2 Porównanie wyników po optymalizacji


Zestawiono wyniki sprzed i po optymalizacji, aby pokazać jak zmiana wag klas czy parametr C wpłynął na dokładność i skuteczność wykrywania odejścia klienta przez model.

```
PODSUMOWANIE WYNIKÓW OPTYMALIZACJI MODELU CHURN
-----
Accuracy po optymalizacji: 0.741582
F1-Score po optymalizacji: 0.622073

PORÓWNANIE DO WYNIKU BAZOWEGO (MICE_Std):
Zmiana Accuracy: -0.059432
Zmiana F1-Score: +0.032924

NAJLEPSZE PARAMETRY:
- C: 0.3
- class_weight: balanced
- fit_intercept: True
- penalty: l2
- tol: 1e-05
-----
```

Rysunek 20: Wyniki po optymalizacji modelu.



Rysunek 21: Porównanie modelu przed i po optymalizacji na danych z walidacji krzyżowej.

Przeprowadzony proces optymalizacji hiperparametrów pozwolił na uzyskanie finalnej konfiguracji modelu, która charakteryzuje się najwyższą skutecznością w wykrywaniu zjawiska *Churn*. Kluczowe wnioski:


- **Wzrost miary F1** - Najważniejszym osiągnięciem na które zwrócono szczególną uwagę jest podwyższenie wyniku F1 do poziomu około 6,2221%. Wzrost o ponad 3 punkty procentowe względem modelu bazowego potwierdza, że precyzyjne dostrojenie parametrów pozwala lepiej wyznaczać granice decyzyjne algorytmu.
- **Efekt zbalansowania klas** - Zastosowanie parametru, który pozwolił nadać wagę klasom fundamentalnie zmieniło zachowanie modelu. Choć ogólna dokładność (ACC) spadła do poziomu 74,1%, model przestał ignorować mniejszościową klasę klientów odchodzących.
- **Z punktu biznesowego** - Uzyskany spadek dokładności o ok. 6 p.p. jest akceptowalny w zamian za wzrost czułości. Z punktu widzenia firmy model jest bardziej wartościowy, ze względu wychwytywanie na większej liczby zagrożonych klientów.

9.3.3 Macierz pomyłek po optymalizacji

Dla analizowanego modelu sporządzono macierz pomyłek po optymalizacji i porównano we wnioskach różnice z macierzą sprzed tego procesu.

Wnioski na podstawie macierzy pomyłek po optymalizacji:

- **Wzrost czujności w klasie pozytywnej** - Zwiększenie wagi na klasę pozytywną, czyli odejście od firmy klienta sprawiło wzrost klasyfikacji próbek jako pozytywna. Model poprawnie zidentyfikował aż 1046 przypadków odejść, redukując liczbę pominiętych rekordów (FN) z 604 do zaledwie 262.
- **Zmiana w klasie negatywnej** - Zastosowanie zbalansowanych wag klas spowodowało wzrost błędu typu TP (błędne uznanie osoby lojalnej za odchodzącego) do poziomu 1012. Z biznesowego punktu widzenia oznacza to częstsze kierowanie akcji retencyjnych do osób lojalnych, co jest jednak akceptowalnym kosztem w zamian za znacznie wyższą skuteczność wykrywania realnych rezygnacji.
- **Czułość** - Model wyłapuje około 80% wszystkich faktycznych odejść (wzrost z poziomu 54%), co pokazuje, że optymalizacja pozwoliła na skuteczne wyodrębnienie cech charakterystycznych dla grupy, która prawdopodobnie odejdzie od korzystania z usług, mimo ich podobieństwa do grupy lojalnej.
- **Precyzja** - Gdy model wskazuje, że ktoś odejdzie, ma rację w około 51% przypadków (spadek z poziomu 65%). Wynika to z uczulenia modelu na klasę mniejszościową.



Rysunek 22: Macierz pomyłek po optymalizacji.

Podsumowanie:

Macierz dokładnie pokazuje przyczyny wzrostu wyniku F1 do poziomu 62%. Model przestał być zachowawczy, dzięki zastosowaniu zbalansowanych wag klas znacznie aktywniej poszukuje klientów zagrożonych odejściem. Choć skutkuje to wyższą liczbą fałszywych alarmów, model przestał przegapiać większość klientów odchodzących, co było problemem w wersji przed optymalizacją. Ostateczny dobór parametrów zależy od przeznaczenia modelu - czy ma szukać raczej pewnych klientów do odejścia, czy też zbierać grupę, która jest zagrożona odejściem.

9.3.4 Ostateczny test na zbiorze testowym

Powtórzone test zoptymalizowanego modelu na wydzielonym (30%) zbiorze testowym.

```

=== OSTATECZNA EWALUACJA MODELU (ZBIÓR TESTOWY 30%) ===
-----
Data testu: 2026-05-14
Najlepszy wariant: MICE + Standaryzacja

METRYKI KOŃCOWE:
Accuracy: 0.742546
F1-Score: 0.624309

MACIERZ POMYŁEK (TEST):
True Negative (TN): 1117
False Positive (FP): 435
False Negative (FN): 109
True Positive (TP): 452

✓ SZCZEGÓŁOWY RAPORT KLASYFIKACJI:

```

		precision	recall	f1-score	support
	0	0.91	0.72	0.80	1552
	1	0.51	0.81	0.62	561
	accuracy			0.74	2113
	macro avg	0.71	0.76	0.71	2113
	weighted avg	0.80	0.74	0.76	2113

```

-----

```

Rysunek 23: Wyniki modelu po optymalizacji na zbiorze testowym.


Wyniki na zbiorze testowym są niemal identyczne, a nawet minimalnie lepsze niż podczas walidacji krzyżowej. Zbieżność wyników dowodzi, że model ma bardzo dobrą zdolność do uogólniania i nie doszło tu do przetrenowania modelu na danych, którymi był trenowany.

9.3.5 Macierz pomyłek na zbiorze testowym

Ostatnim etapem weryfikacji modelu było wygenerowanie macierzy pomyłek dla danych testowych, których model nie widział w procesie nauki ani optymalizacji.

Wnioski na podstawie macierzy pomyłek na danych testowych:

- **Wysoka czujność w klasie pozytywnej** - Model poprawnie zidentyfikował 45 przypadki faktycznych odejść klientów (TP), pomijając jedynie 109 rekordów (FN). Model wykrywa ponad około 81% wszystkich rezygnacji.
- **Skuteczność w klasie negatywnej** - Model trafnie rozpoznał 1117 lojalnych klientów (TN). Liczba błędnych wskazań odejścia dla osób, które pozostały w firmie (FP: 435), utrzymuje się na poziomie akceptowalnym przy tak wysokiej czułości modelu.
- **Precyzja** - W warunkach testowych model, wskazując zagrożenie odejściem, ma rację w co drugim przypadku. Wynik ten jest stabilny względem etapu treningowego.




Rysunek 24: Macierz pomyłek po optymalizacji.

Podsumowanie:

Macierz pomyłek na zbiorze testowym potwierdza gotowość modelu. Uzyskany rozkład błędów jest niemal identyczny z wynikami walidacji krzyżowej, co ostatecznie dowodzi, że model nie jest przetrenowany i posiada wysoką zdolność do uogólniania wiedzy.

9.3.6 Użycie AutoML

W celu weryfikacji i porównania wybranej przez metody utworzono test związany z użyciem AutoML, przy użyciu biblioteki MLJAR, która działa na zasadzie inteligentnego przeszukiwania wieloetapowego. AutoML to inteligentny program do automatyzacji uczenia maszynowego, który przeprowadza własną serię zaawansowanych prób, testując różne algorytmy i ich konfiguracje. Po konfiguracji ustawień związanych z maksymalnym czasem wyszukiwania optymalnego modelu pod kątem miary F1, zwrócono wyniki i porównano je z tymi uzyskanymi przez użyty model. Wykonano 4 próby AutoML trwające kolejno maksymalnie: 1, 2, 5 i 10 minut, a uzyskane wyniki przedstawiono na wykresie porównawczym z użytymi modelami w projekcie. Wszystkie 4 próby zwróciły wynik F1 na poziomie około 52,796% na zbiorze testowym.



Rysunek 25: Porównanie wyniku F1 z AutoML.

Podsumowanie:

Zoptymalizowany model Regresji Logistycznej osiągnął na zbiorze testowym wynik F1-score na poziomie 62,431%, podczas gdy zaawansowany automat MLJAR (Ensemble) zatrzymał się na 52,796% (wynik nie uległ zmianie przy wydłużeniu czasu z 60 sekund do 10 minut). Eksperyment wykazał, że automatyczne frameworki w domyślnych trybach nie zawsze przynoszą optymalne rezultaty, ustępując autorskiemu podejściu o blisko 10 p.p.. Głównymi przyczynami wyższości zaimplementowanego modelu nad systemem AutoML są:

- **Strategia balansu klas** - Kluczowe okazało się wymuszenie parametru balansu klas. AutoML nie wyważył optymalnie tego parametru.
- **Specyfika modeli Ensemble** - Łączenie predykcji wielu słabszych kla-

syfikatorów przez automat doprowadziło do uśrednienia ich błędów i podatności na szum informacyjny. W tych warunkach pojedynczy, dobrze nastrojony model liniowy wykazał znacznie lepsze zdolności generalizacyjne.

10 Podsumowanie

Celem projektu było stworzenie modelu klasyfikacyjnego zdolnego do przewidywania rezygnacji klientów (zjawisko *Churn*). Po przeprowadzeniu szeregu testów, porównaniu 32 kombinacji przygotowania danych oraz finalnej optymalizacji, sformułowano następujące wnioski:

- **Skuteczność modelu** - Finalny model oparty na Regresji Logistycznej z imputacją MICE i Standaryzacją osiągnął stabilny wynik F1 na poziomie około 62% oraz Accuracy na poziomie około 74%. Wyniki te utrzymały się na zbiorze testowym, co potwierdza wysoką wiarygodność modelu.
- **Kluczowa rola optymalizacji** - zbalansowanych wag klas było przełomowym momentem projektu. Pozwoliło to zwiększyć czułość modelu z poziomu 54% na 81%. Z perspektywy biznesowej oznacza to, że model wykrywa około 4 na 5 planujących odejście klientów.
- **Metodyka przygotowania danych** - Projekt pokazał lepszą skuteczność zaawansowanych metod imputacji danych takich jak MICE, która w połączeniu ze standaryzacją cech znacząco poprawia stabilność algorytmów liniowych. Dzięki temu model lepiej radzi sobie z szumem informacyjnym w danych.
- **Zdolność do generalizacji danych** - Brak rozbieżności między wynikami walidacji krzyżowej, a finalnym testem dowodzi, że model odporny jest na przetrenowanie i zachowuje swoją skuteczność dla nowych, nieznanych wcześniej danych.
- **Ocena skuteczności** - Ostateczny wynik należy uznać za dobry, zwłaszcza biorąc pod uwagę wiele elementów losowych, które mają wpływ na decyzje klientów, a są niemożliwe do zebrania w formie danych mających decydować o jego możliwym podejściu. Udało się uzyskać pewną pulę danych, która definiuje kogoś kto planuje odejście i na tej podstawie wrzucić go do grupy zagrożonej odejściem od usług.
- **Wnioski biznesowe** - Opracowane rozwiązanie stanowi skuteczne narzędzie wspierające procesy utrzymania klienta. Model pozwala na precyzyjne wytypowanie grupy wysokiego ryzyka, co umożliwia firmie podjęcie celowanych działań retencyjnych i minimalizację strat finansowych wynikających z odpływu klientów.

Literatura

- [1] Chris Deotte. S6e3 original dataset (telco customer churn). <https://www.kaggle.com/datasets/cdeotte/s6e3-original-dataset>, 2024.
- [2] Geo-y20. Telco customer churn analysis and prediction. <https://github.com/Geo-y20/Telco-Customer-Churn->, 2020. Projekt obejmujący pełny cykl życia modelu: od pogłębionej analizy EDA po wdrożenie rekomendacji biznesowych.
- [3] Roderick J. A. Little and Donald B. Rubin. *Statistical Analysis with Missing Data*. John Wiley & Sons, 3rd edition, 2019.
- [4] John W. Tukey. *Exploratory Data Analysis*. Addison-Wesley, 1977.