

Wstępny Raport

Miłosz Gronowski

`milosz.gronowski@student.pk.edu.pl`

10 kwietnia 2026

1 Abstrakt

Celem projektu jest analiza danych klientów firmy telekomunikacyjnej oraz przygotowanie ich do zadania klasyfikacji polegającego na przewidywaniu odejścia klienta od usług firmy.

W ramach pracy zostaną przeprowadzone procesy wstępnego przetwarzania danych i metody imputacji danych. Ostatecznym celem projektu jest przygotowanie modelu klasyfikacji do przewidywania odejścia danego klienta od firmy oraz analiza wpływu zastosowanych metod na jakość naszej predykcji.

2 Wprowadzenie

Jednym z głównych wyzwań, przed którymi stoi wiele przedsiębiorstw, szczególnie w dynamicznych sektorach rynku, jest utrzymanie klienta. Wysoka konkurencja sprawia, że użytkownicy mogą łatwo zmieniać dostawcę usług, co prowadzi do strat finansowych dla firm.

Analiza zachowań klientów i identyfikacja czynników wpływających na ich decyzje, pozwala na skuteczniejsze zbieranie danych na temat obszarów, które powodują przepływy klientów oraz egzekucję przyjętej strategii firmy.

Dzięki temu przedsiębiorstwa mogą poprawiać jakość swoich usług oraz dostosowywać ofertę do potrzeb klientów.

3 Zbiór danych

W projekcie wykorzystano zbiór danych "Telco Customer Churn" [1], który zawiera informacje o klientach firmy telekomunikacyjnej. Zbiór ten obejmuje ponad 7000 rekordów oraz ponad 20 cech opisujących klientów.

Dane zawierają zarówno zmienne numeryczne (np. miesięczne opłaty, całkowite koszty, długość trwania umowy), jak i kategoryczne (np. płeć, rodzaj usług, typ umowy). Zmienną docelową jest zmienna binarna określająca, czy klient zrezygnował z usług (eng. Churn).

Szczegółowy opis i analiza kolumn znajdujących się w zbiorze danych:

- **CustomerID** - unikalny identyfikator klienta,
- **Gender** - płeć klienta,
- **SeniorCitizen** - informacja, czy klient jest seniorem,
- **Partner** - informacja, czy klient posiada partnera,
- **Dependents** - informacja, czy klient posiada osoby na utrzymaniu,
- **Tenure** - liczba miesięcy korzystania z usług,
- **PhoneService** - informacja, czy klient posiada usługę telefoniczną,
- **MultipleLines** - informacja, czy klient posiada wiele linii telefonicznych,
- **InternetService** - rodzaj usługi internetowej (DSL, Fiber optic, brak),
- **OnlineSecurity** - informacja o posiadaniu usługi bezpieczeństwa online (Tak, Nie, Brak usługi internetowej),
- **OnlineBackup** - informacja o usłudze tworzenia kopii zapasowych (Tak, Nie, Brak usługi internetowej),
- **DeviceProtection** - informacja o ochronie urządzeń (tak, nie, brak usługi internetowej),
- **TechSupport** - informacja o wsparciu technicznym (tak, nie, brak usługi internetowej),
- **StreamingTV** - informacja o usłudze streamingu telewizji (tak, nie, brak usługi internetowej),
- **StreamingMovies** - informacja o usłudze streamingu filmów (tak, nie, brak usługi internetowej),
- **Contract** - typ umowy (miesięczna, roczna, dwuletnia),
- **PaperlessBilling** - informacja o elektronicznym fakturowaniu,
- **PaymentMethod** - sposób płatności (Electronic check, Mailed check, Bank transfer (automatic), Credit card (automatic)),
- **MonthlyCharges** - miesięczna opłata za usługi,
- **TotalCharges** - całkowity koszt poniesiony przez klienta,
- **Churn** - zmienna docelowa określająca odejście klienta, na jej podstawie przeprowadzamy ostateczną klasyfikację.

Zbiór danych zawiera zarówno dane demograficzne, jak i informacje dotyczące korzystania z usług, co pozwala na kompleksową analizę czynników wpływających na decyzję klienta o odejściu.

Ostateczny rezultat projektu pozwala zobrazować, które czynniki są kluczowe w kontekście utrzymania klienta przy ofercie, a także które często prowadzą do tego, że klient rozstaje się z usługami przedsiębiorstwa.

4 Przegląd literatury

Analiza odpływu klientów jest jednym z najczęściej badanych zagadnień w sektorze telekomunikacyjnym, gdzie pozyskanie nowych klientów często jest wiele droższe od utrzymania obecnego. Przeglądając literaturę związaną z zagadnieniem klasyfikacji, dużą wagę przykładają do jakości wejściowych danych i ich wpływu na precyzję modelu. Prace takie jak te autorstwa Little'a i Rubina [3], pokazują wyższą skuteczność zaawansowanych metod imputacji w dopasowywaniu danych. Projekty, takie jak "Telco Customer Churn" z repozytorium Geo-y20 [2] pokazują częste użycie klasyfikatorów Random Forest oraz XGBoost ze względu na odporność na wartości odstające. W przytoczonym projekcie poza samą klasyfikacją, autor skupił się także na aspekcie biznesowym i dostarczeniu rekomendacji, a także rozszerzyli proces o zaawansowane eksploracje danych (EDA) [4], by zrozumieć profil klienta skłonnego do rezygnacji z usług.

5 Motywacja

Jako analityk sprzedaży z zawodu lubię podchodzić w sposób analityczny do pewnych danych związanych bezpośrednio ze sprzedażą, świadczeniem usług, decyzjami konsumentów, czy klientów oraz śledzeniem tego, co stoi za wyborem przez nich, tego czy innego produktu.

Wiem także, jak dużym wyzwaniem dla biznesu jest zrozumienie mechanizmów, które stoją za lojalnością i decyzjami klienta oraz jak duża jest potrzeba na zbieranie wartościowych i merytorycznych danych dla procesu preewaluacji, ewaluacji oraz postewaluacji. Konstruktywne wnioski budowane na podstawie zgromadzonych i uporządkowanych danych, mogą znacząco ulepszyć sposób kierowania oferty dla konsumenta i poprawić jakość świadczonych usług.

Skuteczna analiza pozwala podnosić świadomość skutków, które mogą mieć pewne decyzje biznesowe i sposoby świadczenia usług. Projekty jak te, pozwalają na próbę wyciągnięcia rekomendacji dla danego przedsiębiorstwa i zbadania korelacji pewnych czynników w odniesieniu do zarządzania firmą.

W odniesieniu tych stwierdzeń do wybranego zbioru danych - zgromadzony materiał posiada wiele różnorodnych cech, na którym mogę przetestować proces analizy danych dla konkretnego przedsiębiorstwa, przeanalizować wyniki i zależności pomiędzy danymi, a ostateczną decyzją o odejściu od usług firmy. Pozwala także spróbować wyciągnąć ostateczne wnioski i rekomendacje na ich podstawie.

6 Ewaluacja

Głównym celem ewaluacji jest weryfikacja metod wstępnego przetwarzania danych i ich wpływ na jakość końcowej skuteczności predykcji modelu klasyfikacyjnego w kontekście przewidywania, czy klient odejdzie od usług, czy nie na podstawie zgromadzonych danych.

Predykcje na temat projektu i oczekiwany wynik:

- **Oczekiwany wynik porównania metod imputacji** - zaawansowane metody imputacji danych takie jak np. algorytm KNN czy techniki AutoML, powinny zachować większą spójność danych niż proste metody statystyczne np. średnia, mediana, moda. Satysfakcjonującym wynikiem będzie wykazanie różnic w skuteczności modelu pomiędzy ośmioma wariantami zbioru danych, które będą wygenerowane w procesie preprocesingu,
- **Wskaźnik czułości odejścia klienta** - z punktu czysto biznesowego, ważny będzie wysoki wskaźnik *Recall* (czułość) dla klasy pozytywnej (odejście klienta). Koszt przeoczenia klienta zamierzającego odejść (False Negative) jest znacznie wyższy niż koszt błędnego zaklasyfikowania zostającego klienta do grupy ryzyka (False Positive),
- **Potencjał wdrożeniowy** - Wynik na poziomie F1-score powyżej 75-80% powinien być satysfakcjonujący, aby brać pod uwagę predykcje modelu. Taki model mógłby stanowić pewnego rodzaju "czerwoną lampkę", która może służyć do wczesnego ostrzegania, generując listy rankingowe klientów do działu zajmującego się utrzymaniem klienta przy usługach firmy, co pozwoliłoby na podejmowanie proaktywnych działań naprawczych,
- **Analiza zależności** - Sukcesem będzie nie tylko wysoka trafność predykcji, ale także czytelność modelu – czyli możliwość wskazania, które cechy mają największy wpływ na decyzję o odejściu, co umożliwi sformułowanie konkretnych rekomendacji i wniosków. Znaczący wpływ danej cechy na odejście klienta od firmy, może świadczyć o konieczności poprawy oferty z uwzględnieniem danej cechy,

Projekt ma także na celu próbę sformułowania wniosków i rekomendacji w zakresie ulepszania jakości świadczonych usług, poprzez analizę głównych cech, które ostatecznie mają wpływ na decyzje klienta o zakończeniu pobierania usług.

7 Zasoby

Wykorzystywane zasoby:

- **Visual Studio Code** - główne środowisko programistyczne, wykorzystywane do edycji kodu i zarządzania projektem,
- **Python 3.12** - język programowania stanowiący fundament implementacji wszystkich algorytmów,
- **Notebook Jupyter** - struktura dokumentująca proces projektu, pozwalająca na jednoczesne uruchamianie kodu, prezentację wyników oraz zamieszczanie opisów analitycznych,

Biblioteki i pakiety:

- **Pandas** - główne narzędzie do wczytywania zbioru danych, czyszczenia i transformacji tabelami,
- **Numpy** - biblioteka wykorzystywana do obliczeń numerycznych,
- **Matplotlib i Seaborn** - biblioteki służące do generowania niezbędnych wizualizacji, takich jak: histogramy, wykresy pudełkowe (box-plot) oraz mapy korelacji,
- **Sklearn** - wykorzystana do implementacji zaawansowanych algorytmów uzupełniania braków danych poprzez moduły, takie jak KNN czy MICE,

Metody imputacji danych:

W celu uzupełnienia brakujących wartości (10% dla każdej cechy) oraz zbadania wpływu sposobu uzupełniania danych na spójność logiczną zbioru, zastosowano cztery zróżnicowane strategie, które opisano w dziale Zastosowane metody - Imputacja braków danych 8.3.

8 Zastosowane metody

W projekcie wykorzystano zestaw metod służących do kompleksowej obróbki danych, radzenia sobie z brakami, standaryzacją oraz analizą danych klientów firmy telekomunikacyjnej. Każda z metod została dobrana tak, aby umożliwić porównanie różnych podejść i ocenę ich wpływu na końcowy zbiór danych.

8.1 Czyszczenie danych

- Usunięcie kolumny **CustomerID** z powodu występowania wyłącznie unikalnych danych, co przekłada się na brak wartości informacyjnej i ryzyko przeuczenia,

8.2 Tworzenie braków w danych

- Ze względu na pełną kompletność i zgodność typów danych w każdej kolumnie naszego zbioru danych, stworzono losową metodą sztuczne braki - 1/10 danych dla każdej kolumny z wyłączeniem kolumny **Churn**, która odpowiada za końcową klasyfikację,
- Wartości w kolumnach **OnlineSecurity**, **OnlineBackup**, **DeviceProtection**, **TechSupport**, **StreamingTV**, **StreamingMovies** są zależne od wartości kolumny **InternetService** - jeżeli jej wartość wskazuje na brak usługi internetowej, wszystkie te kolumny mają wartości *No internet Service* - w naszym przypadku jednak tworzymy sztuczne braki również w tych kolumnach, prowadzi to do abstrakcyjnych rekordów w utworzonych zbiorach danych, ale pomoże lepiej zobrazować różnice w użytych metodach imputacji danych,

- Na potrzeby imputacji danych zmieniamy typ danych dla kolumn, które muszą być numeryczne do obliczeń statystycznych - kolumna **TotalCharges**,
- Zmieniamy typ kolumny z Float64 na Int64 - kolumna **SeniorCitizen**,

8.3 Imputacja braków danych

Zastosowano kilka metod imputacji, aby umożliwić porównanie ich wpływu na dane:

- **Prosta metoda statystyczna** – bazowe podejście polegające na uzupełnianiu braków wartością mediany dla danych numerycznych (odporność na wartości odstające) oraz mody dla danych kategoriycznych (najczęstsza wartość),
- **Prosta metoda losowości** – metoda wstawiania losowo wybranych wartości spośród już istniejących w danej kolumnie, co pozwala na zachowanie naturalnego rozkładu cechy bez sztucznej koncentracji wokół średniej,
- **KNN (K-Nearest Neighbors)** – zaawansowane modelowe uzupełnianie danych, gdzie brakująca wartość jest estymowana na podstawie k ($k = 5$) najbardziej podobnych rekordów (sąsiadów) w wielowymiarowej przestrzeni cech,
- **Iterative Imputer (MICE / AutoML-style)** – zaawansowana metoda klasy modelowej, wykorzystująca regresję do przewidywania braków, traktuje ona każdą cechę jako funkcję pozostałych zmiennych, co pozwala na zachowanie głębokich korelacji logicznych w zbiorze danych,

9 Eksperyment


9.1 Preprocessing

9.1.1 Wprowadzenie do preprocessingu

Wczytano zbiór danych, usunięto kolumny unikalne, sprawdzono braki w danych i utworzono je sztucznie dla procesu imputacji danych. Przetestowano cztery metody imputacji.

9.1.2 Rozkład klasyfikacji

Cecha *Churn* na, której bazujemy naszą klasyfikację ma lekką dysproporcję (ok. 3:1 na rzecz klientów, którzy nie odeszli). Na podstawie tego wykresu możemy stwierdzić, że podczas procesu trenowania modeli klasyfikacyjnych, należy zwrócić szczególną uwagę na metryki, które pozwolą skuteczniej wykryć mniejszościową klasę klientów odchodzących.



Rysunek 1: Rozkład klasyfikacji - cecha *Churn*

9.1.3 Eksperyment porównawczy metod imputacji dla kolumn zależnych od siebie

Wprowadzono braki danych w cechach kategoriycznych, które są zależne od usługi internetowej. Pozwoliło to na sprawdzenie, jak poszczególne metody imputacji (KNN, AutoML) radzą sobie z logicznymi zależnościami między kolumnami. Całość porównano także z oryginalnym zbiorem danych.

Oryginalny zbiór danych nie posiadał żadnych błędów logicznych, co pozwoliło zbadać jak różne metody imputacji poradzą sobie z tym problemem. Zbadano poszczególne metody za pomocą dwóch wskaźników:

- Ilości niepoprawnych wartości (wartości YES/NO w kolumnach zależnych przy braku serwisu internetowego oraz wartości NO INTERNET SERVICE w kolumnach zależnych przy posiadaniu serwisu internetowego)
- Ilości niepoprawnych rekordów (co najmniej jedna niepoprawna wartość w rekordzie).

Omówienie wyników analizy jakości imputacji:

- **Prosta metoda statystyczna** – wygenerowała błędy w 11,66% rekordów, wynika to z faktu, że metoda przypisuje najczęściej występującą wartość bez analizy korelacji poszczególnych cech, w efekcie klientom bez in-

ternetu przypisano wartości sugerujące korzystanie z usług dodatkowych, wynik ten mógłby być znacznie wyższy przy innym rozkładzie cech, szczególnie widać tu duże różnice pomiędzy kategoriami przez użycie najczęściej występującej wartości

Błędne przypisania:

- YES: 0
- NO: 857
- NO INTERNET SERVICE: 877

Niepoprawne logicznie:

- WARTOŚCI: 3,44%
- REKORDY: 11,66%

- **Prosta metoda losowości** – wygenerowała błędy w 20,73% rekordów, wprowadziła błędy w każdej kategorii, co czyni zbiór danych niewiarygodnym do dalszych analiz predykcyjnych

Błędne przypisania:

- YES: 590
- NO: 809
- NO INTERNET SERVICE: 1383

Niepoprawne logicznie:

- WARTOŚCI: 5,41%
- REKORDY: 20,73%

- **KNN (K-Nearest Neighbors)** – metoda po zastosowaniu kodowania porządkowego (Ordinal Encoding) wykazała się różną skutecznością, pomimo tego, że znacznie lepiej od prostych metod potrafi identyfikować braki usług, wykazuje jednak błędy na poziomie 12,79% rekordów za sprawą kopiowania zachowań "sąsiadów" - algorytm błędnie dobiera wartości na podstawie podobieństwa demograficznego, czy finansowego, algorytm ma tendencję kopiowania statusu usług w kolumnach zależnych, pomimo tego że status posiadania usługi internetowej może się różnić w tych rekordach

Błędne przypisania:

- YES: 24
- NO: 28
- NO INTERNET SERVICE: 992

Niepoprawne logicznie:

- WARTOŚCI: 2,05%

– REKORDY: 12,79%


- **Iterative Imputer (MICE / AutoML-style)** – metoda iteracyjna uzyskała najwyższy wskaźnik rekordów z błędem logicznym - 23,80% rekordów, wynikający głównie z błędnej klasyfikacji usług u klientów posiadających internet, model regresyjny MICE, szukając globalnych korelacji, nadmiernie generalizuje cechy wspólne dla osób o niskich przychodach lub specyficznych pakietach usług, przypisując im status braku internetu niezgodnie z prawdą

Błędne przypisania:


- YES: 0
- NO: 590
- NO INTERNET SERVICE: 2121

Niepoprawne logicznie:

- WARTOŚCI: 5,37%
- REKORDY: 23,80%



Rysunek 2: Porównanie procentowe ilości niepoprawnych logicznie wartości



Rysunek 3: Porównanie procentowe ilości niepoprawnych logicznie rekordów

Po skończonym eksperymencie związanym z badaniem, jak metody poradzą sobie z kolumnami zależnymi dodano przy imputacji poprawki na uzupełnianie dane, tak by w finalnych zbiorach nie było już błędów logicznych:

- Dla błędów YES/NO - czyli przypisaniu tych wartości do rekordów bez usługi internetowej - zamieniamy je w procesie poprawiania na wartość No INTERNET SERVICE
- Dla błędów No INTERNET SERVICE - czyli przypisaniu tej wartości do rekordów z usługą internetową - zamieniamy je na wartości YES/NO losując je zgodnie z rozkładem proporcji istniejących rekordów - robimy to dla każdej metody


9.1.4 Macierze korelacji

Analiza macierzy korelacji stanowiła ważny etap weryfikacji jakości imputacji, pozwalała porównać korelacje cech dla oryginalnego zbioru danych i poszczególnych metod imputacji.


Wizualna analiza porównawcza pokazała różnice w nasyceniu barw, co przekłada się na powiązania cech:

- **Metoda statystyczna** - zaobserwowano zjawisko mniejszego nasycenia barw w kluczowych blokach numerycznych, takich jak relacja *MonthlyCharges* i *TotalCharges*, wynika to z faktu, że imputacja wartością stałą np. medianą, modą sztucznie ogranicza wariancję, prowadząc do niedoszacowania powiązań cech.

- **Metoda losowa** - wyższy poziom szumu informacyjnego, powstanie przypadkowych powiązań w obszarach o niskiej korelacji
- **Metody KNN i MICE** - wykazały najwyższą zbieżność wizualną z oryginałem, szczególnie widać spójność cech dla relacji *MonthlyCharges* i *TotalCharges*, która jest bardziej nasycona jak w oryginale




Rysunek 4: Macierz korelacji - oryginalny zbiór



Rysunek 5: Relacja MonthlyCharges i TotalCharges dla oryginalnego zbioru



Rysunek 6: Relacja MonthlyCharges i TotalCharges dla prostej metody statystycznej



Rysunek 7: Relacja MonthlyCharges i TotalCharges dla metody MICE


Podsumowanie i wybór optymalnych metod

Na podstawie analizy macierzy korelacji, za najbardziej efektywne metody uznano zaawansowane metody imputacji - KNN, MICE. Najpełniej oddają charakterystykę oryginalnego zbioru, eliminując typowe błędy dla metod prostych. Największą przewagą zaawansowanych metod jest zachowanie hierarchii ważności zmiennych. Bardzo ważne okazało się także upewnienie się, że w zbiorach nie występują błędy logiczne.

9.1.5 Wykresy rozkładu


Celem analizy wykresów rozkładu jest weryfikacja, w jakim stopniu wybrane techniki imputacji zachowały naturalną charakterystykę statystyczną zbioru danych. Porównanie rozkładów gęstości (KDE) pozwala na identyfikację anomalii, takich jak np. przesunięcie spodziewanych wartości. Analizie poddano numeryczne cechy: *tenure*, *MonthlyCharges* oraz *TotalCharges*.

Tenure (Staż klienta)



Rysunek 8: Rozkład stażu klienta (*tenure*) dla zbioru oryginalnego.

W zbiorze oryginalnym cecha posiada rozkład bimodalny. Widać dwie dominujące grupy - nowi klienci (staż poniżej 5 miesięcy) oraz lojalni klienci (staż powyżej 65 miesięcy).




Rysunek 9: Zestawienie linii gęstości KDE dla cechy *tenure* — porównanie metod.

Wnioski i analiza porównawcza: Nałożenie linii gęstości pozwala pokazać wady i zalety poszczególnych metod:


- **Metoda statystyczna** - drastyczne zniekształcenie rozkładu, przez wysoki wzrost wartości około 30 miesięcy, spowodowane użyciem mediany do uzupełnienia braków w danych
- **Metody losowa, KNN i MICE** - najwyższa zbieżność z oryginałem, zachowując wygląd rozkładu
- **Anomalia metody MICE** - linia MICE jako jedyna wykracza poza zakres od 0 do 80 przez matematyczny charakter metody, która bez przycięcia może generować wartości fizycznie niemożliwe

MonthlyCharges (Opłaty miesięczne)



Rysunek 10: Rozkład opłat miesięcznych (*MonthlyCharges*) dla zbioru oryginalnego.

W zbiorze oryginalnym cecha posiada rozkład wielomodalny. Największe grupy klientów są w okolicach wartości 20 - podstawowe usługi, większe wznieśnienie jest także w okolicach wartości 50-110 - rozszerzone usługi.




Rysunek 11: Zestawienie linii gęstości KDE dla cechy *MonthlyCharges* — porównanie metod.

Wnioski i analiza porównawcza: Nałożenie linii gęstości pozwala pokazać wady i zalety poszczególnych metod:


- **Metoda statystyczna** - największa zmiana rozkładu przez użycie mediany w okolicy wartości 70, nienaturalny, wysoki szczyt
- **Metody losowa** - najwyższa zbieżność z oryginałem, zachowując wygląd rozkładu, dobre wyniki metody dla wykresów rozkładu
- **Metoda KNN** - wysoka zgodność, szczególnie w pierwszym ekstremum lokalnym w szczycie niskich opłat
- **Metoda MICE** - minimalny rozjazd względem oryginalnego zbioru, tendencja do lekkiego wygładzania przejść między lokalnymi ekstremami

TotalCharges (Łączne opłaty)



Rysunek 12: Rozkład łącznych opłat (*TotalCharges*) dla zbioru oryginalnego.

W zbiorze oryginalnym cecha posiada wyraźny rozkład prawoskośny. Największa liczebność występuje dla niskich wartości (nowi klienci), natomiast wraz ze wzrostem kwoty liczebność systematycznie spada, tworząc tzw. długi ogon rozkładu.



Rysunek 13: Zestawienie linii gęstości KDE dla cechy *TotalCharges* — porównanie metod.

Wnioski i analiza porównawcza: Nałożenie linii gęstości pozwala pokazać wady i zalety poszczególnych metod:


- **Metoda statystyczna** - największa zmiana rozkładu, mediana wprowadziła sztuczne wybrzuszenie w okolicy wartości 1500, niszcząc płynność przejścia rozkładu prawoskośnego
- **Metoda losowa i KNN** - wykazują niemal idealne pokrycie z linią oryginału
- **Metoda MICE** - bardzo dobra zgodność, choć podobnie jak w przypadku *tenure*, widoczna jest anomalia w postaci generowania wartości poniżej zera

Podsumowanie analizy rozkładów Zbiorcza analiza trzech kluczowych cech numerycznych pozwala na sformułowanie jednoznacznych rekomendacji:


- Dyskwalifikacja metody statystycznej: Użycie mediany w każdym przypadku doprowadziło do powstania nienaturalnych szczytów, które drastycznie zaniżają zgodność zbioru
- Pozostałe metody poprawnie zachowują wykres rozkładu, szczególnie metoda losowa i metoda KNN
- Metoda MICE powinna mieć ograniczenie przed wartościami nierealnymi, gdyż generowała wartości fizycznie niemożliwe ze względu na swój charakter

9.1.6 Wykresy pudełkowe

Sporządzono box-ploty dla każdego z czterech datasetów oraz oryginału. Różnice pomiędzy metodami losową, KNN i MICE są znikome, poprawnie odtworzyły rozstrzał danych oryginalnych. Różnica natomiast występuje w metodzie statystycznej, gdzie wykres pudełkowy może wydawać się nieco węższy, a wąsy krótsze, ponieważ sztuczne wstawienie tej samej wartości (mediany) w wiele miejsc ściąga rozkład do środka, sztucznie zaniżając zmienność. Nie odnotowano punktów poza wąsami wykresów.



Rysunek 14: Wykresy pudełkowe dla metody prostej statystycznej.




Rysunek 15: Wykresy pudełkowe dla metody MICE

9.1.7 Wykresy relacji (pair-plots)


Sporządzono pair-ploty dla każdego z czterech datasetów. Różnice pomiędzy metodami losową, KNN i MICE są znikome i pokazują naturalne rozkłady, podczas gdy metoda statystyczna pokazuje znaczące błędy na wartościach mediany. Dla metody statystycznej pojawiają się nienaturalne "linie" punktów, dla porównania metoda MICE ma punkty płynnie rozproszone.

Zaobserwowano silną, prawie liniową zależność pomiędzy stażem, a opłatami całkowitymi co jest logicznie uzasadnione. Mimo silnego wymieszania się

grup klientów odchodzących i pozostających, można zauważyć pewne tendencje i trendy skupiania się klas. Klasa klientów odchodzących (kolor zielony) dominuje u osób z krótszym stażem oraz relatywnie wyższych opłatach miesięcznych. Klasa klientów pozostających (kolor niebieski) przeważa u osób z dłuższym stażem oraz niższych opłatach. Same te wykresy mogą sugerować już pewne hipotezy, na temat tego gdzie może być pole do poprawy, aby utrzymać większą część klientów. Mimo widocznych trendów, brakuje wyraźnie odseparowanych skupisk, co sugeruje, że separacja klas będzie wymagała nieliniowych modeli uczenia maszynowego, by wyciągnąć większą liczbę zależności i poprawnie klasyfikować przypadki graniczne.



Rysunek 16: Wykres pair-plot dla metody prostej statystycznej.



Rysunek 17: Wykresy pair-plot dla metody MICE

9.1.8 Standaryzacja

Przeskalowano zmienne w celu ujednolicenia zakresów wartości wszystkich cech, by zapobiec dominacji zmiennych o dużych wartościach. Zastosowano dwa warianty standaryzacji:

- **Wariant A (Normalizacja Min-Max)** - przekształcenie danych do sztywnego przedziału $[0, 1]$, metoda zachowuje oryginalną strukturę rozkładu, ale jest wrażliwa na wartości odstające
- **Wariant B (Standaryzacja Z-Score)** - centruje dane wokół średniej równej 0 z odchyleniem standardowym wynoszącym 1, podejście rekomendowane dla większości algorytmów klasyfikacyjnych, takich jak regresja logistyczna czy maszyny wektorów nośnych (SVM).

Dla każdego datasetu uzyskanego czterema metodami imputacji, stworzono po dwa warianty - A i B.

9.2 Trening modelu

9.3 Optymalizacja

10 Podsumowanie

Literatura

- [1] Chris Deotte. S6e3 original dataset (telco customer churn). <https://www.kaggle.com/datasets/cdeotte/s6e3-original-dataset>, 2024.
- [2] Geo-y20. Telco customer churn analysis and prediction. <https://github.com/Geo-y20/Telco-Customer-Churn->, 2020. Projekt obejmujący pełny cykl życia modelu: od pogłębionej analizy EDA po wdrożenie rekomendacji biznesowych.
- [3] Roderick J. A. Little and Donald B. Rubin. *Statistical Analysis with Missing Data*. John Wiley & Sons, 3rd edition, 2019.
- [4] John W. Tukey. *Exploratory Data Analysis*. Addison-Wesley, 1977.